

第2章 統計的な推測

第2節 統計的な推測

(中心極限定理と大数の法則)


母比率と標本比率

- 母比率


- 母集団全体の中である特性を持つ要素の割合
- 例えば、工場で生産されているネジの不良品の割合など

- 標本比率

- 標本の中である特性を持つ要素の割合
- 例えば、工場で生産されているネジを100個集めた標本の中での不良品の割合など




その特性を持つかどうかの二択なので、
二項分布が使えるそうですね！



(再掲) 二項分布の正規分布による近似

二項分布 $B(n, p)$ に従う確率変数 X は、 n が大きい時、近似的に正規分布 $N(np, npq)$ に従う。ただし、 $q = 1 - p$ である。



$n = 30$ や
 $n = 50$ は確かに
正規分布っぽいですね！


母比率と二項分布、正規分布

ある特性を持つデータの母比率を p とする十分大きな母集団から、標本サイズ n の標本を無作為抽出するとき、標本の中でその特性を持つものの個数を T とすると、 T は $B(n, p)$ に従う。

また、標本サイズ n が十分大きいとき、 $q = 1 - p$ とすると二項分布の正規分布近似より、 T は $N(np, npq)$ に従う。



n は標本サイズ、 p は母比率です。
 n は既知ですが、
 p は推測したい対象なので未知です。



標本比率の正規分布近似

標本サイズ n が十分に大きいとき、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う

ゆる証明


ある特性を持つものの個数 T に対し、
標本比率 $R = \frac{T}{n}$ とすると R は確率変数である。

二項分布の正規分布近似より

T は近似的に $N(np, npq)$ に従うので、

T の $\frac{1}{n}$ 倍である R も近似的に正規分布に従う。

(続く)



標本比率の正規分布近似

標本サイズ n が十分に大きいとき、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う

(再掲) T は近似的に $N(np, npq)$ に従うので、 $R = \frac{T}{n}$ も近似的に正規分布に従う。

ゆる証明の続き

$$E[R] = E\left[\frac{T}{n}\right] = \frac{1}{n}E[T] = \frac{1}{n} \cdot np = p$$

$$V[R] = V\left[\frac{T}{n}\right] = \frac{1}{n^2}V[T] = \frac{1}{n^2} \cdot npq = \frac{pq}{n}$$

よって、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う ■

標本サイズ100の標本を140個用意し、標本比率140個を並べる


標本サイズ n が十分に大きいとき、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う



Pythonで実験してみると
確かに正規分布っぽい




140回の無作為抽出で得られた標本比率の分布



標本比率から母比率をゆるく推定する

標本サイズ n が十分に大きいとき、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う

→ 母比率 p は $E[R]$ 付近にありそう (分散 $\frac{pq}{n}$ にもよるが)



工場の全てのネジを
調べなくても不良品の割合
が推測できますね！



例題（視聴率推定）

あるTV番組の視聴率を調べるため、全国から無作為に400人を選んで調査したところ、80人がその番組を見ていた。ただし、母比率 p は未知である。

- (1) この調査における標本比率 R の実現値 r を求めよ。
- (2) R が近似的に従う分布を、 p を用いて答えよ。
- (3) 母比率 p 、つまり視聴率はどの値付近と推測できるか。
(答え方の例：50%付近と推測できる)

$$q = 1 - p$$

標本サイズ n が十分に大きいとき、標本比率 R は近似的に $N(p, \frac{pq}{n})$ に従う



(3) はこの場限りのゆるふわな言い回しです。ちゃんとした推測は後ほど扱います。

例題（視聴率推定） 解答

あるTV番組の視聴率を調べるため、全国から無作為に400人を選んで調査したところ、80人がその番組を見ていた。ただし、母比率 p は未知である。

- (1) この調査における標本比率 R の実現値 r を求めよ。
- (2) R が近似的に従う分布を、 p を用いて答えよ。
- (3) 母比率 p 、つまり視聴率は何%付近と推測できるか。


解答

$$(1) \quad r = \frac{80}{400} = 0.2$$

- (2) 標本サイズ n が400と十分大きいので、 R は $N(p, \frac{p(1-p)}{400})$ に近似的に従う。
- (3) 20%付近と推測できる。

中心極限定理

母平均 m 、母分散 σ^2 の任意の母集団から標本サイズ n の無作為標本を抽出し、標本平均を $\bar{X}$ とする。 n が十分に大きい時、 $\bar{X}$ は近似的に $N(m, \frac{\sigma^2}{n})$ に従う。



標本比率だけでなく、標本平均も
近似的に正規分布に従います！
統計学における
2大最強定理の1つです！




母集団が正規分布のときの標本平均が従う分布

母集団が $N(m, \sigma^2)$ のとき、標本サイズ n に関わらず、 $\bar{X}$ は $N(m, \frac{\sigma^2}{n})$ に従う。

例えば
共通テストの得点分布が
 $N(m, \sigma^2)$ だと仮定したとき、
 $n = 5$ でも $n = 3$ でも、
もっというと $n = 1$ でも
 $\bar{X}$ は $N(m, \frac{\sigma^2}{n})$ に従う。

($n = 1$ の時は X が $N(m, \sigma^2)$
に従うと言ってるだけだが)



例題

魔法使いに細工されたサイコロの出た目の母平均を m を推定したい。
母分散を σ^2 とおき、 m, σ^2 は未知とする。

- (1) このサイコロを30回振って出た目を標本としたとき、標本平均 $\bar{X}$ はどのような分布に近似的に従うか。 m, σ^2 を使って表せ。30回は十分大きいとする。
- (2) (1) の標本の標本平均は5.1であった。母平均 m はどの値付近を取るか、推測せよ。(答え方の例：3.5付近と推測できる)



サイコロに魔法をかけました (笑)

n が十分に大きい時、 $\bar{X}$ は近似的に $N(m, \frac{\sigma^2}{n})$ に従う。

例題 解答

魔法使いに細工されたサイコロの出た目の母平均を m を推定したい。

母分散を σ^2 とおき、 m, σ^2 は未知とする。

- (1) このサイコロを30回振って出た目を標本としたとき、標本平均 $\bar{X}$ はどのような分布に近似的に従うか。 m, σ^2 を使って表せ。30回は十分大きいとする。

解答

標本サイズ $n = 30$ と十分に大きいので、中心極限定理より、 $\bar{X}$ は $N(m, \frac{\sigma^2}{30})$ に従う。

n が十分に大きい時、 $\bar{X}$ は近似的に $N(m, \frac{\sigma^2}{n})$ に従う。

例題 解答

魔法使いに細工されたサイコロの出た目の母平均を m を推定したい。

母分散を σ^2 とおき、 m, σ^2 は未知とする。

(2) (1) の標本の標本平均は5.1であった。母平均 m はどの値付近と推測できるか？ (答え方の例：3.5付近と推測できる)

解答

$\bar{X}$ は $N(m, \frac{\sigma^2}{30})$ に近似的に従う。

30回振って $\bar{x} = 5.1$ であるので、母平均 m は5.1付近と推測できる。



よりしっかりと推測したければ、例えば標本サイズ n を増やすと良いですね！

例題

母平均50、母標準偏差20を持つ母集団から、標本サイズ（大きさ）100の無作為標本を抽出するとき、その標本平均 $\bar{X}$ が54より大きい値をとる確率を求めよ。



母集団の分布は全くわかりませんが、
中心極限定理から $\bar{X}$ は $N(m, \frac{\sigma^2}{n})$ に従いますね！
その上で $P(\bar{X} > 54)$ を考えれば良さそうです。

例題 解答

母平均50、母標準偏差20を持つ母集団から、標本サイズ（大きさ）100の無作為標本を抽出するとき、その標本平均 $\bar{X}$ が54より大きい値をとる確率を求めよ。

解答

母平均 $m = 50$ 、母標準偏差 $\sigma = 20$ 、であり、中心極限定理からこの標本平均 $\bar{X}$ は近似的に

正規分布 $N\left(50, \frac{20^2}{100}\right)$ 、すなわち $N(50, 4)$ に従う。

$m = 50$ 、 $\sigma^2 = 4$ より、 $\bar{X}$ を標準化した Z について、 $Z = \frac{\bar{X} - 50}{2}$ は近似的に $N(0, 1)$ に従う。 $\bar{X} = 54$ とすると、 $Z = 2$ なので

$$P(\bar{X} > 54) \approx P(Z > 2) = 0.5 - p(2) = 0.5 - 0.4772 = 0.0228$$

練習問題 解答

母平均50、母標準偏差20を持つ母集団から、標本サイズ（大きさ）400の無作為標本を抽出するとき、その標本平均 $\bar{X}$ が49より小さい値をとる確率を求めよ。

解答

母平均 $m = 50$ 、母標準偏差 $\sigma = 20$ 、であり、中心極限定理からこの標本平均 $\bar{X}$ は近似的に

正規分布 $N\left(50, \frac{20^2}{400}\right)$ 、すなわち $N(50, 1)$ に従う。

$m = 50$ 、 $\sigma^2 = 1$ より、 $\bar{X}$ を標準化した Z について、 $Z = \frac{\bar{X} - 50}{1}$ は近似的に $N(0, 1)$ に従う。 $\bar{X} = 49$ とすると、 $Z = -1$ なので

$$P(\bar{X} < 49) \approx P(Z < -1) = 0.5 - p(1) = 0.5 - 0.3413 = 0.1587$$

大数の法則

母平均 m の母集団から標本サイズ n の無作為標本を抽出するとき、その標本平均 $\bar{X}$ は n が大きくなるにつれ、母平均 m に近づく。

n が大きくなるほど、
標本平均の分散は
0に近づく

中心極限定理
と並ぶ、統計学の
最強定理です！




標本平均の分散はなぜ n で割るのか

$$V[\bar{X}] = \frac{\sigma^2}{n} \text{ は標本平均の散らばりである。}$$

標本サイズ n が大きい場合は、標本平均の値は母平均に近づきそう
→ データがあまり散らばらない

例えば、学年平均60点のテストで
40人のクラス平均点が80点になるような
ことはほぼない。



40人の平均を取ればそんなに
散らばらない